

Aprendizado de Máquina - MO444

Exercício 2

Aluno: Paulo Ricardo Finardi. RA: 144809

0 Preliminares

Para a solução do exercício **não foi utilizado** a função `GridsearchCV` da biblioteca `sklearn` (essa é a *única* restrição que consta no enunciado do exercício).

Foi utilizado Python 3 na resolução dos exercícios. O código abaixo é o *header* de todos os itens.

```
1 import numpy as np
2 import pandas as pd
3 import csv
4 from sklearn import cross_validation
5 from sklearn.svm import SVC
6
7 # lendo os dados dada1.csv com o Pandas
8 data1 = pd.read_csv('data1.csv')
9
10 # excluindo a última coluna de data1
11 data1.set_index('clase').to_csv('data.csv', index=None)
12
13 # salvando um novo arquivo em formato csv
14 X = pd.read_csv('data.csv')
15
16 # convertendo os dados em numpy-array
17 data1 = data1.as_matrix(columns=None)
18 X = X.as_matrix(columns=None)
19
```

```
20 # y é o conjunto da classe (rótulo 0 ou 1)
21 y = data1[:, 166]
```

0.1 Estratégia

A solução deste exercício segue rigorosamente o enunciado do exercício. Com um pouco mais de detalhes, considere os comentários em cada trecho do enunciado.

Leia os dados do arquivo `data1.csv`. A classe de cada dado é o valor da última coluna (0 ou 1).

Sem observações.

Treine um SVM com kernel RBF nos dados do arquivos.

Nesse trecho, realizamos o SVM em todo o conjunto de dados. Não existe nenhuma menção em tomar qualquer parcela para conjunto de treino/teste.

A validação externa deve ser 5-fold estratificado.

Utilizamos a função `cross_validation` da biblioteca `sklearn`. Não existe restrições ao uso dessa função.

Para cada conjunto de treino da validação externa faça um 3-fold para escolher os melhores hiperparâmetros para C (cost) e γ .

Realizado laços individuais para cada conjunto de treino.

Faça um grid search de para o C nos valores 2^{-5} , 2^{-2} , 2^0 , 2^2 , e 2^5 e γ nos valores 2^{-15} , 2^{-10} , 2^{-5} , 2^0 , e 2^5

Processo realizado sem o uso da função `GridSearchCv`.

1) Qual a accuracy média (na validação de fora).

Resposta: Entendemos como "validação de fora" todo o conjunto dado. A acurácia média foi medida pela função `score` da biblioteca `sklearn`; essa função retorna a acurácia média. Realizamos o *cross-validation* estratificado com os hiperparâmetros C e γ imutáveis (em *default*) e *kernel* = *rbf*. Nessas condições, obtemos **90.1%** de acurácia média.

2) Quais os valores de C e γ a serem usados no classificador final (fazer o 3-fold no conjunto todo).

Resposta: Após o 3-fold em cada um dos 5 conjuntos de treinamento (obtidos do conjunto inicial). O melhor valor para o conjunto $\{C, \gamma\}$ de hiperparâmetros é: $\{2^5, 2^{-5}\}$. Com esses valores em validação 3-fold para todo o conjunto, obtemos acurácia média **91.4%** (ganho de **1.3%** em relação a questão 1).

NÃO use funções prontas que já fazem o grid search como `GridSearchCV` do `sklearn` ou o `tune`

do pacote e1070 do R. Neste exercício eu quero que vocês façam os loops explicitamente. Não utilizado.

1 Código

O primeiro bloco de código refere-se a este trecho do enunciado: *Treine um SVM com kernel RBF nos dados do arquivos. A validação externa deve ser 5-fold estratificado.*

```
1 # criando um SVM classificador
2 svc = SVC(kernel='rbf')
3
4 # criando a validação cruzada estratificada
5 skf = cross_validation.StratifiedKFold(y, n_folds=5)
6
7 # treinando e avaliando
8 scores = [svc.fit(X[train], y[train]).score(X[test], y[test]) for train, test in skf]
9 score = [float(round(n, 3)) for n in scores]
10 print(score)
11
12 # média dan of scores
13 print('\nMean: %.3f' % np.mean(scores))
```

Respectivamente, os resultados das linhas 10 e 13:

```
[0.865, 0.885, 0.947, 0.884, 0.926]
```

```
Mean: 0.901
```

O segundo bloco de código refere-se a este trecho do enunciado: *Para cada conjunto de treino da validação externa faça um 3-fold para escolher os melhores hiperparâmetros para C e γ . Faça um grid search de para o C nos valores 2^{-5} , 2^{-2} , 2^0 , 2^2 , e 2^5 e γ nos valores 2^{-15} , 2^{-10} , 2^{-5} , 2^0 , e 2^5 .*

```
1 # seleção individual de cada conjunto de treino/teste
2 mylist_skf = list(skf)
3 index = [None]*5
4 test = [None]*5
5
6 for i in range(0,5):
```

```

7     index[i], test[i] = mylist_skf[i]
8
9     # conjuntos individuais de treino com o respectivo conjunto de classe.
10    X_15, y_15 = X[index[0]], y[index[0]] # conjunto treino/rotulo 1/5
11    X_25, y_25 = X[index[1]], y[index[1]] # conjunto treino/rotulo 2/5
12    X_35, y_35 = X[index[2]], y[index[2]] # conjunto treino/rotulo 3/5
13    X_45, y_45 = X[index[3]], y[index[3]] # conjunto treino/rotulo 4/5
14    X_55, y_55 = X[index[4]], y[index[4]] # conjunto treino/rotulo 5/5
15
16    # variação do hiperparâmetro C
17    c_range = [np.power(2.0,i) for i in [-5, -2, 0, 2, 5]]
18
19    # variação do hiperparâmetro gamma
20    gamma_range = [np.power(2.0,i) for i in range(-15, 6, 5)]

```

Primeiro loop para o Grid Search conjunto 1/5

```

1    # conjunto 1 de 5
2    for c in c_range:
3        print('\n', 'Para C = %f' % c)
4        for gamma in gamma_range:
5            print('Com gamma = %f' % gamma)
6            svc = SVC(C = c, gamma = gamma, kernel='rbf')
7            kf = cross_validation.KFold(len(X_15), n_folds=3) # 3-fold
8            scores = [ svc.fit(X_15[train], y_15[train]).score(X_15[test], y_15[test])
9                       for train, test in kf ]
10           score = [float(round(n, 3)) for n in scores]
11           print('Acurácia em 3-fold: ', score, '. Média da acurácia: %.3f' % np.mean(score))

```

O resultado da linha 11 é:

```

Para C = 0.031250
Com gamma = 0.000031
Acurácia em 3-fold: [0.535, 0.575, 0.587] . Média da acurácia: 0.566
Com gamma = 0.000977
Acurácia em 3-fold: [0.535, 0.575, 0.587] . Média da acurácia: 0.566

```

Com gamma = 0.031250
 Acurácia em 3-fold: [0.535, 0.575, 0.587] . Média da acurácia: 0.566
 Com gamma = 1.000000
 Acurácia em 3-fold: [0.535, 0.575, 0.587] . Média da acurácia: 0.566
 Com gamma = 32.000000
 Acurácia em 3-fold: [0.535, 0.575, 0.587] . Média da acurácia: 0.566

Para C = 0.250000
 Com gamma = 0.000031
 Acurácia em 3-fold: [0.535, 0.575, 0.587] . Média da acurácia: 0.566
 Com gamma = 0.000977
 Acurácia em 3-fold: [0.559, 0.591, 0.722] . Média da acurácia: 0.624
 Com gamma = 0.031250
 Acurácia em 3-fold: [0.567, 0.614, 0.659] . Média da acurácia: 0.613
 Com gamma = 1.000000
 Acurácia em 3-fold: [0.535, 0.575, 0.587] . Média da acurácia: 0.566
 Com gamma = 32.000000
 Acurácia em 3-fold: [0.535, 0.575, 0.587] . Média da acurácia: 0.566

Para C = 1.000000
 Com gamma = 0.000031
 Acurácia em 3-fold: [0.535, 0.575, 0.587] . Média da acurácia: 0.566
 Com gamma = 0.000977
 Acurácia em 3-fold: [0.764, 0.803, 0.849] . Média da acurácia: 0.805
 Com gamma = 0.031250
 Acurácia em 3-fold: [0.882, 0.882, 0.897] . Média da acurácia: 0.887
 Com gamma = 1.000000
 Acurácia em 3-fold: [0.535, 0.575, 0.587] . Média da acurácia: 0.566
 Com gamma = 32.000000
 Acurácia em 3-fold: [0.535, 0.575, 0.587] . Média da acurácia: 0.566

Para C = 4.000000
 Com gamma = 0.000031
 Acurácia em 3-fold: [0.535, 0.575, 0.587] . Média da acurácia: 0.566
 Com gamma = 0.000977
 Acurácia em 3-fold: [0.85, 0.827, 0.857] . Média da acurácia: 0.845
 Com gamma = 0.031250
 Acurácia em 3-fold: [0.89, 0.906, 0.897] . Média da acurácia: 0.898

```

Com gamma = 1.000000
Acurácia em 3-fold: [0.535, 0.575, 0.587] . Média da acurácia: 0.566
Com gamma = 32.000000
Acurácia em 3-fold: [0.535, 0.575, 0.587] . Média da acurácia: 0.566

Para C = 32.000000
Com gamma = 0.000031
Acurácia em 3-fold: [0.787, 0.78, 0.81] . Média da acurácia: 0.792
Com gamma = 0.000977
Acurácia em 3-fold: [0.913, 0.898, 0.889] . Média da acurácia: 0.900
Com gamma = 0.031250
Acurácia em 3-fold: [0.89, 0.906, 0.897] . Média da acurácia: 0.898
Com gamma = 1.000000
Acurácia em 3-fold: [0.535, 0.575, 0.587] . Média da acurácia: 0.566
Com gamma = 32.000000
Acurácia em 3-fold: [0.535, 0.575, 0.587] . Média da acurácia: 0.566

```

Assim, para o conjunto (1/5) escolhemos C e $gamma$ que possui o maior valor de acurácia média. Logo, $C = 32$ e $gamma = 2^{-5}$ implica em acurácia 89.8%.

```

1  # conjunto 2 de 5
2  for c in c_range:
3      print('\n', 'Para C = %f' % c)
4      for gamma in gamma_range:
5          print('Com gamma = %f' % gamma)
6          svc = SVC(C = c, gamma = gamma, kernel='rbf')
7          kf = cross_validation.KFold(len(X_25), n_folds=3) # 3-fold
8          scores = [ svc.fit(X_25[train], y_25[train]).score(X_25[test], y_25[test])
9                      for train, test in kf ]
10         score = [float(round(n, 3)) for n in scores]
11         print('Acurácia em 3-fold: ', score, '. Média da acurácia: %.3f' % np.mean(score))

```

O resultado da linha 11 é:

```

Para C = 0.031250
Com gamma = 0.000031

```

Acurácia em 3-fold: [0.535, 0.575, 0.587] . Média da acurácia: 0.566
 Com gamma = 0.000977
 Acurácia em 3-fold: [0.535, 0.575, 0.587] . Média da acurácia: 0.566
 Com gamma = 0.031250
 Acurácia em 3-fold: [0.535, 0.575, 0.587] . Média da acurácia: 0.566
 Com gamma = 1.000000
 Acurácia em 3-fold: [0.535, 0.575, 0.587] . Média da acurácia: 0.566
 Com gamma = 32.000000
 Acurácia em 3-fold: [0.535, 0.575, 0.587] . Média da acurácia: 0.566

Para C = 0.250000
 Com gamma = 0.000031
 Acurácia em 3-fold: [0.535, 0.575, 0.587] . Média da acurácia: 0.566
 Com gamma = 0.000977
 Acurácia em 3-fold: [0.535, 0.575, 0.595] . Média da acurácia: 0.568
 Com gamma = 0.031250
 Acurácia em 3-fold: [0.567, 0.614, 0.627] . Média da acurácia: 0.603
 Com gamma = 1.000000
 Acurácia em 3-fold: [0.535, 0.575, 0.587] . Média da acurácia: 0.566
 Com gamma = 32.000000
 Acurácia em 3-fold: [0.535, 0.575, 0.587] . Média da acurácia: 0.566

Para C = 1.000000
 Com gamma = 0.000031
 Acurácia em 3-fold: [0.535, 0.575, 0.587] . Média da acurácia: 0.566
 Com gamma = 0.000977
 Acurácia em 3-fold: [0.724, 0.858, 0.841] . Média da acurácia: 0.808
 Com gamma = 0.031250
 Acurácia em 3-fold: [0.858, 0.898, 0.913] . Média da acurácia: 0.890
 Com gamma = 1.000000
 Acurácia em 3-fold: [0.543, 0.583, 0.587] . Média da acurácia: 0.571
 Com gamma = 32.000000
 Acurácia em 3-fold: [0.535, 0.575, 0.587] . Média da acurácia: 0.566

Para C = 4.000000
 Com gamma = 0.000031
 Acurácia em 3-fold: [0.535, 0.575, 0.587] . Média da acurácia: 0.566
 Com gamma = 0.000977

```

Acurácia em 3-fold: [0.795, 0.85, 0.841] . Média da acurácia: 0.829
Com gamma = 0.031250
Acurácia em 3-fold: [0.89, 0.906, 0.897] . Média da acurácia: 0.898
Com gamma = 1.000000
Acurácia em 3-fold: [0.543, 0.583, 0.587] . Média da acurácia: 0.571
Com gamma = 32.000000
Acurácia em 3-fold: [0.535, 0.575, 0.587] . Média da acurácia: 0.566

```

```

Para C = 32.000000
Com gamma = 0.000031
Acurácia em 3-fold: [0.74, 0.835, 0.833] . Média da acurácia: 0.803
Com gamma = 0.000977
Acurácia em 3-fold: [0.898, 0.921, 0.865] . Média da acurácia: 0.895
Com gamma = 0.031250
Acurácia em 3-fold: [0.89, 0.906, 0.897] . Média da acurácia: 0.898
Com gamma = 1.000000
Acurácia em 3-fold: [0.543, 0.583, 0.587] . Média da acurácia: 0.571
Com gamma = 32.000000
Acurácia em 3-fold: [0.535, 0.575, 0.587] . Média da acurácia: 0.566

```

Assim, para o conjunto (2/5) escolhemos C e γ que possui o maior valor de acurácia média. Logo, $C = 32$ e $\gamma = 2^{-5}$ implica em acurácia 89.8%.

```

1  # conjunto 3 de 5
2  for c in c_range:
3      print('\n', 'Para C = %f' % c)
4      for gamma in gamma_range:
5          print('Com gamma = %f' % gamma)
6          svc = SVC(C = c, gamma = gamma, kernel='rbf')
7          kf = cross_validation.KFold(len(X_35), n_folds=3)
8          scores = [ svc.fit(X_35[train], y_35[train]).score(X_35[test], y_35[test])
9                      for train, test in kf ]
10         score = [float(round(n, 3)) for n in scores]
11         print('Acurácia em 3-fold: ', score, '. Média da acurácia: %.3f' % np.mean(score))

```

O resultado da linha 11 é:

Para C = 0.031250
 Com gamma = 0.000031
 Acurácia em 3-fold: [0.512, 0.591, 0.591] . Média da acurácia: 0.565
 Com gamma = 0.000977
 Acurácia em 3-fold: [0.512, 0.591, 0.591] . Média da acurácia: 0.565
 Com gamma = 0.031250
 Acurácia em 3-fold: [0.512, 0.591, 0.591] . Média da acurácia: 0.565
 Com gamma = 1.000000
 Acurácia em 3-fold: [0.512, 0.591, 0.591] . Média da acurácia: 0.565
 Com gamma = 32.000000
 Acurácia em 3-fold: [0.512, 0.591, 0.591] . Média da acurácia: 0.565

Para C = 0.250000
 Com gamma = 0.000031
 Acurácia em 3-fold: [0.512, 0.591, 0.591] . Média da acurácia: 0.565
 Com gamma = 0.000977
 Acurácia em 3-fold: [0.528, 0.591, 0.606] . Média da acurácia: 0.575
 Com gamma = 0.031250
 Acurácia em 3-fold: [0.535, 0.606, 0.614] . Média da acurácia: 0.585
 Com gamma = 1.000000
 Acurácia em 3-fold: [0.512, 0.591, 0.591] . Média da acurácia: 0.565
 Com gamma = 32.000000
 Acurácia em 3-fold: [0.512, 0.591, 0.591] . Média da acurácia: 0.565

Para C = 1.000000
 Com gamma = 0.000031
 Acurácia em 3-fold: [0.512, 0.591, 0.591] . Média da acurácia: 0.565
 Com gamma = 0.000977
 Acurácia em 3-fold: [0.677, 0.803, 0.827] . Média da acurácia: 0.769
 Com gamma = 0.031250
 Acurácia em 3-fold: [0.866, 0.882, 0.929] . Média da acurácia: 0.892
 Com gamma = 1.000000
 Acurácia em 3-fold: [0.52, 0.598, 0.591] . Média da acurácia: 0.570
 Com gamma = 32.000000
 Acurácia em 3-fold: [0.512, 0.591, 0.591] . Média da acurácia: 0.565

Para C = 4.000000

```

Com gamma = 0.000031
Acurácia em 3-fold: [0.512, 0.591, 0.591] . Média da acurácia: 0.565
Com gamma = 0.000977
Acurácia em 3-fold: [0.756, 0.85, 0.874] . Média da acurácia: 0.827
Com gamma = 0.031250
Acurácia em 3-fold: [0.866, 0.882, 0.929] . Média da acurácia: 0.892
Com gamma = 1.000000
Acurácia em 3-fold: [0.52, 0.598, 0.591] . Média da acurácia: 0.570
Com gamma = 32.000000
Acurácia em 3-fold: [0.512, 0.591, 0.591] . Média da acurácia: 0.565

```

```

Para C = 32.000000
Com gamma = 0.000031
Acurácia em 3-fold: [0.677, 0.803, 0.811] . Média da acurácia: 0.764
Com gamma = 0.000977
Acurácia em 3-fold: [0.858, 0.843, 0.913] . Média da acurácia: 0.871
Com gamma = 0.031250
Acurácia em 3-fold: [0.866, 0.882, 0.929] . Média da acurácia: 0.892
Com gamma = 1.000000
Acurácia em 3-fold: [0.52, 0.598, 0.591] . Média da acurácia: 0.570
Com gamma = 32.000000
Acurácia em 3-fold: [0.512, 0.591, 0.591] . Média da acurácia: 0.565

```

Assim, para o conjunto (3/5) escolhemos C e $gamma$ que possui o maior valor de acurácia média. Logo, $C = 32$ e $gamma = 2^{-5}$ implica em acurácia 89.2%.

```

1 # conjunto 4 de 5
2 for c in c_range:
3     print('\n', 'Para C = %f' % c)
4     for gamma in gamma_range:
5         print('Com gamma = %f' % gamma)
6         svc = SVC(C = c, gamma = gamma, kernel='rbf')
7         kf = cross_validation.KFold(len(X_45), n_folds=3)
8         scores = [ svc.fit(X_45[train], y_45[train]).score(X_45[test], y_45[test])
9                     for train, test in kf ]

```

```

10     score = [float(round(n, 3)) for n in scores]
11     print('Acurácia em 3-fold: ', score, '. Média da acurácia: %.3f' % np.mean(score))

```

O resultado da linha 11 é:

```

Para C = 0.031250
Com gamma = 0.000031
Acurácia em 3-fold: [0.512, 0.591, 0.591] . Média da acurácia: 0.565
Com gamma = 0.000977
Acurácia em 3-fold: [0.512, 0.591, 0.591] . Média da acurácia: 0.565
Com gamma = 0.031250
Acurácia em 3-fold: [0.512, 0.591, 0.591] . Média da acurácia: 0.565
Com gamma = 1.000000
Acurácia em 3-fold: [0.512, 0.591, 0.591] . Média da acurácia: 0.565
Com gamma = 32.000000
Acurácia em 3-fold: [0.512, 0.591, 0.591] . Média da acurácia: 0.565

```

```

Para C = 0.250000
Com gamma = 0.000031
Acurácia em 3-fold: [0.512, 0.591, 0.591] . Média da acurácia: 0.565
Com gamma = 0.000977
Acurácia em 3-fold: [0.512, 0.606, 0.598] . Média da acurácia: 0.572
Com gamma = 0.031250
Acurácia em 3-fold: [0.528, 0.614, 0.63] . Média da acurácia: 0.591
Com gamma = 1.000000
Acurácia em 3-fold: [0.512, 0.591, 0.591] . Média da acurácia: 0.565
Com gamma = 32.000000
Acurácia em 3-fold: [0.512, 0.591, 0.591] . Média da acurácia: 0.565

```

```

Para C = 1.000000
Com gamma = 0.000031
Acurácia em 3-fold: [0.512, 0.591, 0.591] . Média da acurácia: 0.565
Com gamma = 0.000977
Acurácia em 3-fold: [0.709, 0.858, 0.85] . Média da acurácia: 0.806
Com gamma = 0.031250
Acurácia em 3-fold: [0.795, 0.913, 0.937] . Média da acurácia: 0.882
Com gamma = 1.000000
Acurácia em 3-fold: [0.512, 0.591, 0.591] . Média da acurácia: 0.565

```

```
Com gamma = 32.000000
Acurácia em 3-fold: [0.512, 0.591, 0.591] . Média da acurácia: 0.565
```

```
Para C = 4.000000
Com gamma = 0.000031
Acurácia em 3-fold: [0.512, 0.591, 0.591] . Média da acurácia: 0.565
Com gamma = 0.000977
Acurácia em 3-fold: [0.748, 0.843, 0.874] . Média da acurácia: 0.822
Com gamma = 0.031250
Acurácia em 3-fold: [0.843, 0.906, 0.937] . Média da acurácia: 0.895
Com gamma = 1.000000
Acurácia em 3-fold: [0.512, 0.591, 0.591] . Média da acurácia: 0.565
Com gamma = 32.000000
Acurácia em 3-fold: [0.512, 0.591, 0.591] . Média da acurácia: 0.565
```

```
Para C = 32.000000
Com gamma = 0.000031
Acurácia em 3-fold: [0.709, 0.795, 0.85] . Média da acurácia: 0.785
Com gamma = 0.000977
Acurácia em 3-fold: [0.882, 0.858, 0.913] . Média da acurácia: 0.884
Com gamma = 0.031250
Acurácia em 3-fold: [0.843, 0.906, 0.937] . Média da acurácia: 0.895
Com gamma = 1.000000
Acurácia em 3-fold: [0.512, 0.591, 0.591] . Média da acurácia: 0.565
Com gamma = 32.000000
Acurácia em 3-fold: [0.512, 0.591, 0.591] . Média da acurácia: 0.565
```

Assim, para o conjunto (4/5) escolhemos C e $gamma$ que possui o maior valor de acurácia média. Logo, $C = 32$ e $gamma = 2^{-5}$ implica em acurácia 89.5%.

```
1 # conjunto 5 de 5
2 for c in c_range:
3     print('\n', 'Para C = %f' % c)
4     for gamma in gamma_range:
5         print('Com gamma = %f' % gamma)
6
```

```

7     svc = SVC(C = c, gamma = gamma, kernel='rbf')
8     kf = cross_validation.KFold(len(X_55), n_folds=3)
9     scores = [ svc.fit(X_55[train], y_55[train]).score(X_55[test], y_55[test])
10                for train, test in kf ]
11     score = [float(round(n, 3)) for n in scores]
12     print('Acurácia em 3-fold: ', score, '. Média da acurácia: %.3f' % np.mean(score))

```

O resultado da linha 11 é:

```

Para C = 0.031250
Com gamma = 0.000031
Acurácia em 3-fold: [0.516, 0.583, 0.598] . Média da acurácia: 0.566
Com gamma = 0.000977
Acurácia em 3-fold: [0.516, 0.583, 0.598] . Média da acurácia: 0.566
Com gamma = 0.031250
Acurácia em 3-fold: [0.516, 0.583, 0.598] . Média da acurácia: 0.566
Com gamma = 1.000000
Acurácia em 3-fold: [0.516, 0.583, 0.598] . Média da acurácia: 0.566
Com gamma = 32.000000
Acurácia em 3-fold: [0.516, 0.583, 0.598] . Média da acurácia: 0.566

Para C = 0.250000
Com gamma = 0.000031
Acurácia em 3-fold: [0.516, 0.583, 0.598] . Média da acurácia: 0.566
Com gamma = 0.000977
Acurácia em 3-fold: [0.516, 0.583, 0.598] . Média da acurácia: 0.566
Com gamma = 0.031250
Acurácia em 3-fold: [0.516, 0.583, 0.598] . Média da acurácia: 0.566
Com gamma = 1.000000
Acurácia em 3-fold: [0.516, 0.583, 0.598] . Média da acurácia: 0.566
Com gamma = 32.000000
Acurácia em 3-fold: [0.516, 0.583, 0.598] . Média da acurácia: 0.566

Para C = 1.000000
Com gamma = 0.000031
Acurácia em 3-fold: [0.516, 0.583, 0.598] . Média da acurácia: 0.566
Com gamma = 0.000977
Acurácia em 3-fold: [0.695, 0.843, 0.827] . Média da acurácia: 0.788

```

```
Com gamma = 0.031250
Acurácia em 3-fold: [0.828, 0.921, 0.913] . Média da acurácia: 0.887
Com gamma = 1.000000
Acurácia em 3-fold: [0.523, 0.583, 0.606] . Média da acurácia: 0.571
Com gamma = 32.000000
Acurácia em 3-fold: [0.516, 0.583, 0.598] . Média da acurácia: 0.566
```

```
Para C = 4.000000
Com gamma = 0.000031
Acurácia em 3-fold: [0.516, 0.583, 0.598] . Média da acurácia: 0.566
Com gamma = 0.000977
Acurácia em 3-fold: [0.758, 0.85, 0.882] . Média da acurácia: 0.830
Com gamma = 0.031250
Acurácia em 3-fold: [0.867, 0.921, 0.929] . Média da acurácia: 0.906
Com gamma = 1.000000
Acurácia em 3-fold: [0.523, 0.583, 0.606] . Média da acurácia: 0.571
Com gamma = 32.000000
Acurácia em 3-fold: [0.516, 0.583, 0.598] . Média da acurácia: 0.566
```

```
Para C = 32.000000
Com gamma = 0.000031
Acurácia em 3-fold: [0.68, 0.811, 0.819] . Média da acurácia: 0.770
Com gamma = 0.000977
Acurácia em 3-fold: [0.844, 0.89, 0.874] . Média da acurácia: 0.869
Com gamma = 0.031250
Acurácia em 3-fold: [0.867, 0.921, 0.929] . Média da acurácia: 0.906
Com gamma = 1.000000
Acurácia em 3-fold: [0.523, 0.583, 0.606] . Média da acurácia: 0.571
Com gamma = 32.000000
Acurácia em 3-fold: [0.516, 0.583, 0.598] . Média da acurácia: 0.566
```

Assim, para o conjunto (5/5) escolhemos C e $gamma$ que possui o maior valor de acurácia média. Logo, $C = 32$ e $gamma = 2^{-5}$ implica em acurácia 90.6%.

No último bloco de código, refizemos o SVM com os hiperparâmetros $C = 32$, $gamma = 2^{-5}$ e $kernel = \text{RBF}$. **Nessas condições obtemos um ganho de acurácia de 1.4% com relação ao parâmetros em *default*.**

```

1  # SVM nos mesmos dados iniciais, agora com hiperparâmetros turbinados
2  svc = SVC(kernel='rbf', C = 32, gamma = 2**-5)
3
4  # criando a validação cruzada estratificada (mesmo processo do primeiro bloco de código)
5  skf = cross_validation.StratifiedKFold(y, n_folds=5)
6
7  # treinando e avaliando
8  scores = [svc.fit(X[train], y[train]).score(X[test], y[test]) for train, test in skf]
9  score = [float(round(n, 3)) for n in scores]
10 print(score)
11
12 # média dan of scores
13 print('\nMean: %.3f' % np.mean(scores))

```

Respectivamente, os resultados das linhas 10 e 13:

```
[0.911, 0.905, 0.924]
```

```
Mean: 0.914
```